


数据集管理

AI 数据湖服务



法律声明

本《AI 数据湖服务》的所有内容，包括但不限于文字、商标、架构、图示、图片、页面布局等，其知识产权（著作权、商标权、专利权、商业秘密等）归属于北京火山引擎科技有限公司及其关联公司（火山引擎），非经火山引擎书面同意，任何个人和组织不得复制、使用、修改、转发或以任何违反本《AI 数据湖服务》所承载的目的进行传播。

本《AI 数据湖服务》陈述内容仅作为产品的通用性介绍和参考性指引，火山引擎保留按“现状”和“当前可用”的形式提供产品和服务的权利。火山引擎不对本《AI 数据湖服务》中所载的产品功能、性质、质量、标准等内容进行明示或默示的保证和承诺，最终以您与火山引擎实际签署的协议为准。

如您发现本《AI 数据湖服务》有任何错误或歧义，或发现有对本《AI 数据湖服务》、产品本身的侵权行为，请与火山引擎取得联系。

联系方式：service@volcengine.com, 400-850-0030
(周一至周五 10:00-18:00)

目录

法律声明-----1

目录-----1

1. 数据集管理-----1

1. 数据集管理

数据集功能说明

功能概述

数据集 (Dataset) 是按照一定结构和格式组织起来的数据集合，可用于分析、研究、训练、测试。AI 数据集可用于组织、可视化文本或多模态数据样本，还能用于批量清洗、数据标注和探查。在进行模型训练、评测及 AI 数据工作流之前，您需要依据业务类型来创建特定的数据集，支持创建**通用数据集与推理数据集**。

- **通用数据集**：面向AI开发人员的多模态数据集合，为模型训练、评估或研究等场景提供数据支撑。
- **推理数据集**：支持方舟平台大模型推理数据一键回流，为模型精调等场景提供数据支撑，协同方舟，构建模型持续迭代的增强回路。

核心优势

- **覆盖场景广**：端到端数据处理+训练链路 各个节点、各种格式的数据，均可以数据集的形式进行组织和管理。既支持单模态数据集，也支持构建多模态数据集。
- **使用效率高**：数据集和数据处理模块无缝联动，可以在线可视化探查数据处理各个阶段的数据。针对 Lance 格式数据集，提供高效的在线增删改查、sql查询等能力，面向标注场景，人工校验更高效。
- **多模存储性能优**：Lance格式数据集，支持多模数据混合存储。row_id 行级索引和标量/向量/全文等二级索引机制，支持高效的随机点查和混合检索。支持零成本加列，面向机器学习训练场景友好。
- **开放生态**：数据集可纳管存储在 TOS 上的各类数据，可与火山方舟无缝对接，支持模型推理数据回流。支持将las平台加工好的高质量数据集导出到方舟，支持模型训练、精调等场景。

创建数据集

通用数据集

通用数据集说明

通用数据集：用于对齐模型行为的人类偏好数据，通过 SFT 等方式调整模型输出。

操作步骤

1. 登录 [LAS 控制台](#) 。在顶部左上角根据实际情况选择地域。
2. 在左侧导航栏选择 数据集 > 通用数据集，进入数据集列表页面。
3. 点击 创建数据集。页面跳转至数据集参数配置页面，参考参数说明进行配置，完成后单击 **创建**。

三

火山引擎

总览

账号全部资源

华北2（北京）

搜索产品或文档

企业

工具

费用

支持

备案

文档

中文

AI 数据湖服务

创建通用数据集

概览

LAS Agent

数据广场

算子广场

开源库广场

数据集

通用数据集

推理数据集

数据集共享

数据处理

开发机

任务管理

任务实例

工作流

基本信息

高级设置

* 数据集英文名称

las_dataset_20260114_170210

数据集中文名称

请输入

数据集格式

Lance

Iceberg

CSV

JSONL

Parquet

Image

Audio

Video

Text

Lerobot

* 数据来源

对象存储 TOS

文件存储 vePFS

元数据 Catalog

示例文件

tos://

+ 从 TOS 选择

元数据存储

请选择

请输入 table 路径

非必填。选择Catalog路径，向Catalog注册元数据信息。使用默认路径

参数	描述
数据集英文名称	数据集的唯一标识。 长度1-100个字符 仅支持中文、大小写字母、数字开头 仅支持横线"-"及下划线"_"符号，不支持特殊字符
数据集中文名称	数据集的别名。 - 长度1-100个字符 - 仅支持中文、大小写字母、数字开头 - 仅支持横线"-"及下划线"_"符号，不支持特殊字符。
数据集格式	数据集的读取方式。 - Lance: 一种数据湖格式。支持编辑/删除数据项、全文搜索等高级功能。 - Iceberg: 一种数据湖格式。 - CSV: 选择此格式，会读取 数据来源 路径下，以 .csv, .tsv 为后缀的文件 - JSONL: 选择此格式，会读取 数据来源 路径下，以 .jsonl, .json 为后缀的文件 - Parquet: 选择此格式，会读取 数据来源 路径下，以 .parquet 为后缀的文件 - Image/Audio/ Video/Text: - 对于 Image、Audio、Video、Text 这四种格式，如果数据来源的一级目录下有以 metadata 为文件名，且以 json、jsonl、csv、parquet 为后缀的文件，我们将约定此文件为该数据集的描述文件，在描述文件中，约定 file_name 为对应文件的路径，读取对应路径下指定后缀的文件。详

参数	描述
	情请参见下文的数据读取规则说明：Image/Audio/ Video/Text。 ■ 如果没有描述文件： ■ Image：选择此格式，会读取 数据来源 路径下，以 .png, .jpg, .jpeg, .gif, .tiff, .bmp 为后缀的文件 ■ Audio：选择此格式，会读取 数据来源 路径下，以 .mp3, .wav, .flac, .ogg, .m4a, .aac, .pcm, .aiff, .aif 为后缀的文件 ■ Video：选择此格式，会读取 数据来源 路径下，以 .mp4, .mkv, .avi, .mov, .webm 为后缀的文件 ■ Text：选择此格式，会读取 数据来源 路径下，以 .txt 为后缀的文件 ◦ Lerobot: Huggingface 开源的一套机器人工具库，LAS 数据集支持读取 v3.0 版本的 lerobot 数据集，并提供翻页、SQL 查询，以及视频抽帧加载的能力
数据来源	当前支持从对象存储 TOS 、元数据 Catalog中读取数据并创建数据集。 ◦ 对象存储 TOS：选择需要创建为数据集的数据在TOS中的存储路径。 说明 当前仅支持读取同地域的 TOS 中的数据。 ◦ 元数据 Catalog：Lance、Iceberg格式的数据支持直接选择基于 Catalog 来创建数据集。
元数据存储 (部分数据格式支持)	创建Lance、Iceberg格式的数据集时，支持同步将数据集相关元数据注册为 Catalog 中的一张表，便于用户在 Catalog 进行元数据管理和存储优化。

参数	描述
	说明 - 进行此操作时，您需具备在对应 Catalog 中创建表的操作权限。 - 后续如果您删除了对应的数据集，则对应 Catalog 中同步注册的表也会同步删除。

数据读取规则说明：Image/Audio/ Video/Text

对于 Image、Audio、Video、Text 这四种格式，如果数据来源的一级目录下有以 metadata 为文件名，且以 json、jsonl、csv、parquet 为后缀的文件，我们将约定此文件为该数据集的**描述文件**，在**描述文件**中，约定 **file_name** 为对应文件的路径。
以 audio 格式为例，假设数据来源路径为: tos://dataset/audio，目录结构为：

SQL

```
.
├── dataset
│   └── audio
│       ├── audio_1.mp3
│       ├── audio_2.mp3
│       ├── audio_3.mp3
│       ├── desc
│       │   ├── metadata.csv -- 只会读取一级目录下的描述文件，所以此文件不会被识别为描述文件
│       │   └── metadata.jsonl -- 只会读取一级目录下的描述文件，所以此文件会被识别为描述文件
└──
```

在描述文件中，您可以以 **file_name** 来表示文件路径（需要是相对路径），然后用其他列来表示该路径此文件的一些元信息，例如：

JSON

```
{ "file_name": "audio_1.mp3", "size": 1000, "length": 11 }
{ "file_name": "audio_2.mp3", "size": 1000, "length": 29 }
{ "file_name": "audio_3.mp3", "size": 1000, "length": 99 }
```

数据读取规则说明：JSONL、CSV、Parquet

对于JSONL、CSV、Parquet类型的数据集，当前 LAS 支持递归目录寻找实际符合后缀要求的数据。逻辑示例说明如下。

示例1：数据所在目录层级一致	示例2：数据所在目录层级不一致
· 创建数据集时，数据来源设置的TOS路径是： tos://a/ · 实际存储到TOS的数据的路径，只要在同一层，都是可以正常读取数据，比如： ◦ tos://a/b/1.parquet ◦ tos://a/b/2.parquet ◦ tos://a/b/3.parquet ◦ tos://a/c/4.parquet ◦ tos://a/c/5.parquet ——虽然实际数据存储在TOS时，数据路径的第2层有的是“b”、有的是“c”，但是最终的数据都在第3层，则数据集也是可以读到所有的1.parquet~5.parquet的所有数据。	· 创建数据集时，数据来源设置的TOS路径是： tos://a/ · 实际存储到TOS的数据的路径，只要在同一层，都是可以正常读取数据，比如： ◦ tos://a/b/1.parquet ◦ tos://a/b/2.parquet ◦ tos://a/b/c/3.parquet ◦ tos://a/4.parquet ——实际数据存储在TOS时，数据路径层级不一致，最终仅能正常读取数据来源配置的路径下的数据，即，本示例仅可正常读取 4.parquet 这条数据。


推理数据集

推理数据集说明

推理数据集是大模型实际应用场景中的用户输入数据集合，反映真实用户需求分布。

LAS AI 数据集与火山方舟协同支持大模型推理数据回流。您可在火山方舟中将指定的自定义推理接入点的数据，以加密的形式投递至您的专属私有 AI 数据湖中，未经授权时您的数据唯您所有、仅您可见、仅您可用。由此借助 LAS 强大的多模态数据处理能力，开展包括预训练、评测、DPO 偏好对齐、SFT 微调、回流等下游任务，持续优化大模型训练效果，以契合业务场景需求。

以发起数据回流服务为例，若需获取详细说明，请查看下列视频。



前提条件

- 已创建火山方舟账户，且具备火山方舟 Standard 或以上权限。
- 在火山方舟内完成创建自定义推理接入点，详见[查看并管理推理接入点](#)，在配置页面须开启数据投递至私有数据湖。

注意

当前仅华北 2（北京）地域支持推理数据集功能。

基本信息

接入点名称

请输入

接入点描述

请输入描述，如接入场景、用途（如测试、线上业务）等。

0/300

接入配置

模型选择

Doubao-1.5-pro-32k | 250115

模型广场

购买方式

按Token付费

付费单位为Token，更加灵活

按模型单元付费

专属算力，对精调后模型表现更优

模型限流


15000 RPM / 30000000 TPM

该账号下访问 doubao-1-5-pro-32k 模型的总限流；您可购买「TPM保障包」为单个接入点提升限流。保障包内限流不包含在账号下模型总限流中，单个接入点超出保障包额度外的流量将与账号下所有接入点共享限流额度。

TPM保障包

弹性流量保障 平台推荐订购

对高流量业务提供资源保障，适合大流量、可预估流量大小，生产级高SLA要求的场景。



当业务预估用量稳定消耗时选择 弹性流量保障 当业务预估用量需要灵活购买时可选择 平台推荐订购

接入点限流

手动设置接入点限流。Tips：如果账号下所有访问同一模型的接入点限流之和等于账号下该模型限流，会更大概率减少不同接入点之间的限流额度争夺。

数据投递至私有数据湖

开启后，该接入点的调用数据将全程加密投递存储到您可见、仅您可用的私有数据湖中。数据存储将产生一定费用，请参考《对象存储计费概述》《LAS计费说明》。

费用细则

接入模型

模型广场/Doubao-1.5-pro-32k/250115

购买方式

按Token付费

计费方式

后付费

结算周期

小时

费用预估

输入价格

0.0004 元/千tokens 折后价

输出价格

0.0010 元/千tokens 折后价

*具体费用以账单为准

确认接入

已开启网络层传输加密

操作步骤

1. 登录 [LAS 控制台](#)。
2. 在顶部左上角根据实际情况选择地域。
3. 在左侧导航栏选择数据集 > 推理数据集，进入推理结果数据集列表页面。
4. 点击前往创建，跳转至火山方舟 > 数据集 > 我的数据湖。

版权所有©北京火山引擎科技有限公司

6/14

火山引擎

默认项目

华北2 (北京)

中文

搜索产品或文档

企业

工具

费用

支持

备案

文档

使用说明

火山方舟

概览页

智能广场

模型广场

应用广场

体验中心

文本模型

语音模型

视觉模型

应用实验室

Prompt 实验室

模型推理

在线推理

批量推理 降价50%

模型定制

模型精调

模型仓库

模型评测

数据集管理

数据集

统一管理数据集，支持多版本管理和数据集共享，可在模型精调中使用数据集

我的数据集

我的数据湖

共享数据集

创建数据集

发起模型推理

管理数据投递

开始日期

结束日期

操作指南

前往AI数据湖编辑数据

调用时间	Request	Response	Model ID	推理
2025-04-21 16:01:48	分析一下世界局势，风口，创业建议，大概100字左右	当前世界局势呈现多极化博弈，地缘冲突与科技竞争交织，能源转型、AI...	doubao-1...nking-pro-250415	ep-20%
2025-04-21 16:01:33	分析一下世界局势，风口，创业建议，大概100字左右	当前世界局势呈现多极化加速，科技竞争白热化，能源转型与地缘波动交织...	doubao-1...nking-pro-250415	ep-20%
2025-04-21 16:00:58	分析一下世界局势，风口，创业建议，大概100字左右	当前世界局势呈现多极化博弈，地缘冲突与科技竞争交织，能源转型、AI...	doubao-1...nking-pro-250415	ep-20%
2025-04-21 14:47:41		类别：风景 图片解读：这是一幅典型的热带海滨风光图，展现了自然景观...	doubao-1...nking-pro-m-250415	ep-20%
2025-04-21 14:47:36		风景	doubao-1...nking-pro-m-250415	ep-20%
2025-04-21 14:47:33	推理模型与非推理模型的区别是什么？	在人工智能和机器学习领域，**推理模型**与**非推理模型**的区别...	doubao-1...nking-pro-m-250415	ep-20%
2025-04-21 14:47:06	推理模型与非推理模型的区别是什么？	推理模型与非推理模型是人工智能领域中两类	doubao-1...nking-pro	ep-20%

数据详情

调用时间: 2025-04-21 16:01:48

Request ID

Model ID

Endpoint ID

Tokens

301

Request 数据预览

{ "model": { "name": "doubao-1-5-thinking-pro", "endpoint_id": "doubao-1-5-g-pro-250415", "version": "250415" }, "messages": [{ "role": "user", "content": "分析一下世界局势，风口，创业..." }] }

共 5,667 条数据，当前预览最近1000条记录中，满足筛选条件的部分数据

1

2

3

4

5

...

20

50条/页

5. 单击**管理数据投递**，在弹出的列表中激活指定的**自定义推理接入点**作为您的数据来源。或者进入接入点详情页开启此项设置。

数据集

统一管理数据集，支持多版本管理和数据集共享，可在模型精调中使用数据集

我的数据集

我的数据湖

共享数据集

创建数据集

发起模型推理

管理数据投递

开始日期

结束日期

操作指南

前往AI数据湖编辑数据

接入点名称/ID	接入模型	创建时间	创建人	数据发送至我的数据湖
Doubao-1.5-thinking-pro 250415 模型广场		2025-04-21 15:27		☒
Doubao-1.5-thinking-pro m-250415 模型广场		2025-04-18 12:03		☒
Doubao-1.5-vision-pro-32k 250115 模型广场		2025-04-15 00:19	--	☒
DeepSeek-V3 250324 模型广场		2025-04-14 16:57		☒
Doubao-embedding-vision 241215 模型广场		2025-04-12 17:43		☒

1

2

3

4

5

6

7

8

10条/页

取消

开启投递



7. 在接入点详情页，单击**对话体验**即可快速调用模型进行对话，也可以通过 API 调用当前**推理接入点**进行访问。对话或者推理数据将自动以结构化形式入库。



8. 单击前往 AI 数据湖服务编辑数据，返回 LAS 控制台 > 数据集 > 推理数据集，查看对应推理数据集。

9. 您可通过工作流对推理数据集进行处理，处理完成后单击导出可将数据保存为通用数据集。




管理数据集

数据查询

数据集创建完成后，您可以点击数据集名称在数据详情中查看基本信息，同时也支持数据内容的在线预览和查询。

数据详情

1. 单击目标数据集的名称进入数据详情页面，单击列名右侧的图标展开筛选。



- 此页面会展示数据集内的具体数据项。不同格式，支持展示程度不同：
 - Lance: 支持翻页、洞察统计、搜索筛选、SQL 查询、编辑/删除、另存为。
 - Iceberg: 支持翻页、洞察统计、搜索筛选、SQL 查询、另存为。
 - JSONL/CSV/Parquet: 支持翻页、SQL 查询。
 - Text/Image/Audio/Video: 仅支持预览十条数据。
 - Lerobot: 支持翻页、SQL 查询。

说明

- **Lance格式数据集多模态数据加载规则**：以列名定义数据模态，且有对应数据类型要求，具体如下：
 - 图像列：列名需以“image”为前后缀，写入Lance时类型为二进制类型。
 - 音频列：列名需以“audio”为前后缀，写入Lance时类型为blob格式的二进制类型。
- **Image/Audio/Video/Text格式数据集查看规则**：
 - 无描述文件：可直接查看图片、试听音频、观看视频或预览文本。
 - 有描述文件：除上述查看操作外，还会展示对应数据的元信息。

- LAS 当前支持通过**文本**、**字符数**筛选表内容，筛选关系可选择**等于/不等于、为空/不为空、包含/不包含以及正则表达式**。

另存为数据集

- **通用数据集**：
 - 当前仅支持 Lance/Iceberg 格式的数据集，通过**另存为**方式将数据集回流至火山方舟。
 - 可依据需求筛选符合方舟精调要求的列，并将其转换为火山方舟精调能识别的格式。
- **推理数据集**：
 - 所有格式均支持通过**另存为**方式将数据集回流至火山方舟。

数据集回流火山方舟总结

1. 通用数据集

- 格式限制：当前仅支持Lance/Iceberg格式。
- 回流方式：通过“另存为”操作实现。
- 额外功能：可按需筛选符合方舟精调要求的列，并转换为其可识别格式。

2. 推理数据集

- 格式支持：无格式限制，所有格式均适用。

。回流方式：通过“另存为”操作实现。

另存为数据集

* 数据集名称

your_dataset_name

* 保存到

火山方舟
模型精调

保存格式

jsonl

* 选择字段 ?

所需内容	选择映射字段
System 系统角色	请选择（可选）
User 提示词	请选择（必选）
Assistant 模型回答	请选择（必选）
Loss_weight 训练权重	请选择（可选）

火山方舟模型精调

生成数据集

取消

确认

参数	描述
数据集名称	另存为方舟数据集时，可以指定数据集名称
保存到	数据集另存为的目的地，暂只支持火山方舟
保存格式	数据集另存为时的格式，暂支持 jsonl
选择字段 System	选择一列作为「系统角色」
选择字段 User	选择一列作为「提示词」
选择字段 Assistant	选择一列作为「模型回答」
选择字段 Loss_weight	选择一列作为「训练权重」

SQL查询

1. 单击目标数据集的名称进入详情页面，选择 SQL 查询进行数据筛查。

2. 在左侧控制台编写 SQL 语句，点击开始查询按钮执行检索任务，右侧显示查询结果。如需重置SQL语句请单击重置按钮。

说明

- 您可在左下角回顾**历史查询**，也可选择 **SQL 模板** 进行快速查询。您只需选择相应模板并运行查询，即可轻松获得准确结果。同时，点击页面右上角的**全屏预览**可进入沉浸式浏览。
- Lance/Iceberg 格式的数据集，SQL 查询引擎为 Datafusion，您的 SQL 应符合 Datafusion 的标准。
- JSONL/CSV/Parquet/Lerobot 格式的数据集，SQL 查询引擎为 DuckDB，您的 SQL 应符合 DuckDB 的规范。
- 为了安全，当前禁用了所有 IO 相关的函数。

文件管理

在此 Tab 页可以查看该路径下的所有文件，并允许上传、预览、删除、下载文件，以及新建文件夹。

操作记录

此 Tab 页会记录数据集的变更操作。

数据新增

支持对数据集新增数据，但新增数据的格式需要与当前数据集的格式相同。

1. 在目标数据集右侧功能项选择**新增**，进入**新增数据**页面。
2. 参数配置会自动依据当前数据集的**数据集名称**、**数据类型**、**格式**进行配置，您只需要添加新增数据的 TOS 路径即可完成新增。


数据导出

支持数据集的导出能力，支持导出至对象存储、火山方舟以及新的版本数据集，用于后续的模式训练。LAS AI 目前支持如下两种方式导出数据。

- 在 **LAS 控制台 > 数据集 > 数据详情** 页面，单击**导出数据**，导出指定数据集。
- 在 **LAS 控制台 > 数据集 > SQL 查询** 页面，将 **SQL 查询结果** 导出。

数据集日志

数据集创建完成后，支持查看数据集的所有操作变更记录，您可以在数据集-操作记录中查看。



数据集权限

数据集的权限体系主要围绕账户角色和可见性设置进行定义。权限分为两个核心类别：**管理权限**和**只读权限**。

1. 在数据集详情页的右上角点击**权限管理**，进入到当前数据集的权限管理页面。



2. 配置**管理权限**与**只读权限**。



权限名称	说明
None	无权限，只能查看数据集列表及数据集摘要信息
Read	读取数据集数据
Edit	编辑数据集数据
Manage	管理数据集元信息、权限，分享与删除数据集

说明

- 授权主体分为两类：**指定用户**与**组织内所有人**。指定用户目前支持用户 / 用户组，可进行模糊搜索；组织内所有人指授权给当前租户内所有用户，后续新增或删除用户依然适用。
- 授权给指定用户支持批量操作，您可同时新增与取消多个授权主体：新增授权时，点击主体前的方框打对勾即可；删除授权时，点击主体前的方框取消对勾即可。
- 数据集创建者与主账号拥有该数据集的管理权限，且不可被剥夺，所以两者无需被授权。